

HARNESS ENGINEERING · 2026

Arreios Digitais

Autoadaptativos

Um assistente que aprende com você

O Hermes, suas skills, e como o harness de um agente virou a alavanca mais importante da engenharia de IA.

Ney Lemke · CIO UNESP · CTInf · 2026

O que um LLM cru não faz

Um modelo de linguagem treinado **não é um agente**. Ele:

1. **Esquece tudo** entre conversas — começa do zero a cada prompt
2. **Não vê seus arquivos** — não tem filesystem, não tem contexto de projeto
3. **Não executa ações** — não roda comandos, não lê e-mail, não agenda reunião
4. **Alucina com confiança** — inventa paths, APIs, fatos, clientes
5. **Não aprende com erros** — amanhã repete o mesmo bug de hoje

| *Sem ajuda externa, o LLM é um autocomplete glorificado.*

Os 5 ingredientes que transformam LLM em agente

Para cada limite, um ingrediente resolve:

Limite do LLM	Ingrediente que resolve
Esquece entre conversas	Memória persistente em camadas (3 tiers)
Não vê seus arquivos	Ferramentas — terminal, browser, MCP, file edit
Não executa ações	Skills — procedimentos reutilizáveis versionados
Alucina com confiança	Contexto estruturado (AGENTS.md, contexto da tarefa)
Não aprende com erros	Eval loop — cada falha vira teste, depois regra

Quando esses 5 ingredientes se compõem, o LLM deixa de ser autocomplete e vira ferramenta.

Da combinação nasce o harness

LLM sozinho = autocomplete.

LLM + 5 ingredientes = ferramenta útil.

LLM + 5 ingredientes + orquestração contínua = agente.

Esse sistema ao redor do modelo é o **harness**. E em 2026, a engenharia de harness virou a alavanca mais importante da IA — 6× mais impacto que trocar o modelo, segundo Stanford/Tsinghua.

| *A pergunta deixou de ser "qual modelo usar" e virou "como projetar o sistema que envolve o modelo".*

A metáfora: arreios

Arreios são o conjunto de equipamentos que **conectam o cavalo ao trabalho** — adaptados ao animal, ao terreno, ao propósito.

- Um bom arreio **não atrapalha** — amplifica
- Precisa ser **ajustado** ao usuário, não o contrário
- **Multimodal**: voz, texto, imagem, código, automação
- **Autoadaptativo**: aprende com o uso, evolui entre sessões
- **Versão 2**: agora a metáfora também é o termo técnico do campo — *harness*

O meu dia a dia exige mais que um LLM

Sou CIO da UNESP, professor, pesquisador. Minhas demandas misturam domínios que **um único LLM nu não dá conta**:

Domínio	Exemplo real	Por que o LLM sozinho não basta
Programação	PRs em Rust, debug de drivers, code review	Precisa ler arquivos, rodar testes, abrir PR
Burocracia	Ofícios à RNP, editais de licitação, convênios	Precisa de templates, prazos, contexto institucional
Física/Matemática	Simulações, equações, papers, notas de aula	Precisa de LaTeX, plots, bibliografia
Bioinformática	Pipelines de sequenciamento, BLAST, phylogenia	Precisa de datasets reais e ferramentas específicas
Gestão/CTInf	Atas, escalas, chamados, planejamento	Precisa de Notion, calendário, mensagens
Sysadmin	Diagnóstico de crash, drivers NVIDIA, network	Precisa de terminal, journald, ssh
Vida financeira	Imposto de renda, investimentos, orçamento pessoal	Precisa de planilhas, regras fiscais atualizadas, contexto familiar
Cultura	Notas sobre cinema, livros, design	Precisa de contexto do meu gosto pessoal
Bots/agentes	Bot Telegram, perfis de agentes	Precisa de long-running processes

Cada linha dessa tabela tem **contexto proprietário, ferramentas específicas, e regras que mudam com o**

Parte 1 — Contexto introdutório

Como chegamos aqui? A IA em 2026 vive quatro ondas simultâneas.

As quatro paradigmas da engenharia de IA

#	Paradigma	Foco	Quando
1	Prompt Engineering	Como falar com o modelo	2022–2023
2	Context Engineering	O que o modelo vê em cada chamada	2024
3	Agent Engineering	Tools, planning, memory, action	2024–2025
4	Harness Engineering	O sistema inteiro ao redor do modelo	2026 →

- | "Agent = Model + Harness" — Viv Trivedy, 2026
- | "Harness engineering is the discipline of building the runtime control system around an AI agent." — aibuilderclub.com

Por que importou agora?

- **Anthropic** publicou "Effective harnesses for long-running agents" (jan/2026)
- **OpenAI** escreveu "Harness engineering: leveraging Codex in an agent-first world" (fev/2026) — milionário de linhas de código sem humanos digitando
- **Birgitta Böckeler** (Thoughtworks) consolidou em martinowler.com (fev/2026)
- **Addy Osmani** (Google) publicou "Agent Harness Engineering" (mai/2026)
- **Stanford/Tsinghua**: 6× de diferença de performance **só pelo harness**, mesmo modelo

| *O campo está se institucionalizando em meses, não anos.*

O que é "harness" exatamente?

Harness = o sistema que circunda o modelo e decide **como ele pensa, planeja, age, percebe contexto, armazena artefatos e se autocorrige**.


Componentes canônicos (Lilian Weng, jul/2026):

Componente	Responsabilidade
Context files (<code>AGENTS.md</code> , <code>CLAUDE.md</code>)	"README para agentes" — convenções, comandos, regras
Skills	Prompts + tools + docs invocáveis sob demanda
Tools/MCP	Interface padronizada com mundo externo
Sub-agents	Divisão de tarefas longas em paralelas
Hooks	Ganchos de validação (pre/post tool use)
Memory/Playbooks	Contexto como playbook que evolui (ACE, MCE)
Eval loop	Verificação automática de qualidade
Sandbox + Permissions	Limites do que o agente pode fazer

A virada: o modelo virou commodity

2018–2024: melhorar o modelo → melhorar tudo.

2026: melhorar o **harness** → melhorar tudo.



O padrão "ratchet"

Ratchet pattern

Cada falha vira regra permanente no AGENTS.md



Caso OpenAI/Codex — 1M de linhas, zero humanas

Ryan Lopopolo, OpenAI (fev/2026):

- **5 meses** construindo um produto com 1M linhas
- **0 linhas escritas por humanos** (constraint deliberada)
- **3 engenheiros** mantendo **3,5 PRs/dia cada** (subiu para 7 com mesmo ritmo)
- **1500 PRs** mergeados
- **1/10 do tempo** comparado a escrita manual

| *O trabalho humano migrou de "escrever código" para "projetar o ambiente onde o agente escreve código".*

Os 3 loops que importam

Dois padrões de autoaprimoramento dominam 2026:

Loop	Quem usa	Como
ACE (Agentic Context Engineering)	Anthropic, muitos	Generator → Reflector → Curator mantêm um playbook vivo
MCE (Meta Context Engineering)	Frontier labs	Cruza skills via crossover tipo algoritmo genético

| *Hermes usa algo próximo do ACE nas skills: cada falha evolui uma `SKILL.md` em PR.*

Parte 2 — Hermes: o arreio concreto


De teoria para a implementação que roda no seu laptop.

O que é o Hermes em 2026?

- **Agente open source MIT** (Nous Research), **v0.10** → **v0.13** (Tenacity Release)
- 70+ ferramentas built-in, 118 skills bundled
- **6 canais de messaging** num único gateway
- Compatível com agentskills.io (padrão aberto)
- **Modelo-agnóstico**: Anthropic, OpenAI, OpenRouter, local (Ollama)

| Lançado em fev/2026, é hoje o stack open-source de agentes que mais cresce.

Arquitetura: três camadas



6 canais de entrada convergem no **gateway multiplex** → **harness** orquestra o **modelo** e as **ferramentas**.
Memory (3 tiers) e **skills** (agentskills.io) fecham o loop de feedback.

O Hermes É um harness de harness

A stack do Hermes implementa os 8 componentes canônicos:

Componente canônico	Implementação Hermes
Context files	<code>~/.hermes/AGENTS.md</code> , <code>SOUL.md</code> , profile-level
Skills	<code>~/.hermes/profiles/<p>/skills/**/SKILL.md</code> (formato <code>agentskills.io</code>)
Tools/MCP	Tool Gateway + MCP catalog (Telegram, Discord, +15)
Sub-agents	<code>delegate_task</code> + perfis isolados
Hooks	Webhooks + <code>pre/post</code> actions no config
Memory/Playbook	3-tier: core, session_search, providers externos
Eval loop	<code>requesting-code-review</code> skill + GEPA
Sandbox/Perms	<code>TELEGRAM_ALLOWED_USERS</code> , profile isolation

Skills: memória procedimental versionada

Skills library

~118 bundled + custom | formato agentskills.io

```
~/.hermes/profiles/<perfil>/skills/
```

productivity/marp

→ apresentacoes

github/pr-workf

→ PRs

telegram-bot-op

→ cuidar dos bots

agents/jarbas/

→ agente jarbas

research/arxiv/

→ busca papers

diagnose-crash/

→ debugar travame

... ~118 bundled

→ + customizadas

Cada skill = 1 pasta com SKILL.md (YAML frontmatter + corpo)

```
---name: diagnose-crash
---description: Use when investigating crashes, BSODs,
               gateway loops, or system hangs on this Linux/0marchy box.
```

Memória em 3 tiers

Tier	Onde	O que guarda	Latência
1 — Core	MEMORY.md + USER.md (~3.5k chars)	Identidade, preferências, environment facts	Sempre no contexto
2 — Session	SQLite FTS5 pesquisável	Todas as conversas passadas	Sob demanda, rápido
3 — Externo	Notion, Obsidian, MongoDB, QDrant, Redis	Conhecimento profundo, multi-tenant	Integração

Fatos críticos no Tier 1. Detalhes sob demanda nos demais. **Memória profunda é opt-in, não default.**


Gateway multiplex — 6 canais, 1 processo

Antes (v1): um gateway por perfil → conflitos de PID, port collision.
Agora (v2): um único gateway serve **todos os perfis** (linus, montaigne, default...).

```
hermes gateway migrate --multiplex
```

Canal	Status
Telegram	✓ produção
CLI/TUI	✓ local
Slack	✓

Canal	Status
Discord	✓
WhatsApp / Signal	✓
Email (IMAP/SMTP)	✓



Perfis = agentes isolados

```
hermes profile create klimt --clone default  
hermes profile create linus --clone default  
hermes profile create vargani --clone default
```

Cada perfil tem:

- `SOUL.md` próprio (identidade)
- Memória independente
- Bot Telegram dedicado
- Cronjobs separados
- Skills customizadas

Exemplo real que roda hoje:

- `montaigne` — bots, voz, transcrição (o que usamos nesta conversa)
- `linus` — sysadmin, WSL, drivers
- `vargani` — gestão UNESP/CTInf
- `ideker` — bioinformática
- `klimt` — cultura, cinema, design

Perfis que rodam hoje

Na minha máquina, **5 perfis ativos** que separam domínios do trabalho:

Perfil	Papel	Exemplo de uso
montaigne	Bots e voz	Bot Telegram, transcrição de áudio (o que usamos agora)
linus	Sysadmin	Diagnóstico de crash, drivers, journald
vargani	Gestão UNESP/CTInf	Atas, escalas, planejamento institucional
ideker	Bioinformática	Pipelines de sequenciamento, BLAST
klimt	Cultura	Notas sobre cinema, livros, design

Cada perfil é um **sub-agente especializado** com identidade, memória e bot próprio — o mesmo modelo LLM responde a todos, mas com contexto e skills diferentes.

Voz: real-time, nativa


Herald Release (2026.2):

- **Voz conversacional em tempo real**
- Edge TTS como default (pt-BR nativo, zero config)
- STT local via `faster-whisper` (base/small/large-v3)
- Multilingual, switch automático de idioma



Desktop nativo (Surface Release, jun/2026)

- **App desktop nativo** (Electron) — macOS, Linux, Windows
- Painel web de administração (canais, creds, MCP, webhooks)
- **Sessões multi-perfil concorrentes** em abas
- Arrasta-e-solta arquivos no chat
- Conecta a **gateway remoto** (homelab, hosted) via OAuth
- `/undo` para desfazer últimas N turns
- Modelo picker fuzzy no status bar




Parte 3 — Como o trabalho mudou

O dia-a-dia de usar Hermes em 2026.

Antes vs. depois: o workflow

Aspecto	Antes (v1)	Agora (v2)
Onboarding	1h explicando contexto	30s — memória + skills já carregadas
Tarefa nova	Tenta, falha, refaz	Tenta → falha → escreve skill → próximo: resolve na 1ª
Reuniões	Anota e processa depois	Teams bot pipeline: transcrição → skill <code>meeting-action-items</code> → cards no Notion
Diagnóstico	Você debug	<code>diagnose-crash</code> skill: journald + dmesg + last + logs → relatório com causa raiz
Apresentação	Slide por slide	<code>marp</code> skill: estrutura → conteúdo → render → push
PR review	Manual ou amigo	<code>requesting-code-review</code> skill: security + quality gates + auto-fix
Knowledge mgmt	Wiki parada	GEPA evolui skills offline baseado em traces

Caso real: pipeline de reuniões Teams



Pipeline Teams: por dentro

Inputs (Teams bot)

- Áudio da reunião via Herald
- Transcrição com diarização
- Timestamps e participantes

Processamento

- Skill `meeting-action-items` extrai:
 - Decisões com contexto
 - Action items com **owner + due date** inferido
- LLM faz o mapeamento com base no histórico do Tier 2


Outputs (3 destinos paralelos)

- Cards no Notion (board institucional)
- Mensagem no Telegram (lembrete diário)
- Cron 8h: resumo do que está aberto

Caso real: o crash de hoje cedo

O laptop caiu às 9:14 com `hermes-gateway.service` em loop infinito (counter 1155+).

Com a skill `diagnose-crash`, o diagnóstico foi:



Antes: 30 min fuçando logs no escuro. **Agora:** skill resolve em 90 segundos.

```

diagnose-crash skill · terminal

$ /skill diagnose-crash
· Investigating laptop crash at 09:14 today

[+] Collecting evidence
· journalctl --since today -p err
· last -F -n 10
· uptime / boot IDs

[!] ROOT CAUSE IDENTIFIED
hermes-gateway.service restart counter = 1155
Rogue gateway (linus, PID 2526004) holding host
Cold boot forced at 09:14:22 (no graceful shutdown)

[+] RECOMMENDED FIX
$ hermes gateway migrate --multiplex
$ sudo systemctl disable hermes-gateway.service

Skill saved: ~/.hermes/profiles/linus/skills/diagnose-crash/
✓ Diagnostic complete in 87s · Skill updated
  
```

Caso real: skill auto-gerada ontem

O usuário pediu para "verificar se o Telegram está no ar". Em menos de 10 trocas, o Hermes:

1. Tentou `curl` nos DCs públicos → falhou
2. Detectou que IPs individuais falham mas `149.154.166.110` responde
3. Escreveu nota sobre a geolocalização dos DCs do Telegram
4. Propôs criar/atualizar skill `telegram-bot-operations`
5. Em 5 minutos: skill atualizada e testada

Autoedição em tempo real — o arreio **se ajusta durante a montagem**.

```
vim · SKILL.md (auto-generated)

---
name: telegram-bot-operations
description: | Use when managing Telegram bot gateways,
diagnosing polling conflicts, or restarting Hermes
gateway processes. Triggers: 'polling conflict',
'gateway not responding', 'Telegram bot offline'.
version: 2
updated: 2026-09-28T18:51:00
generated_by: auto # ≥5 tool calls → reflect
---

# Telegram Bot Operations


## Common pitfalls

- Never kill the gateway PID directly – use
`hermes gateway restart` to avoid polling conflict.
- Wait 30s between restarts (Telegram session lifetime).
- DCs are geo-distributed: 149.154.166.110 works from BR,
.50 and 91.108.56.130 may TLS-fail.
- Use `getMe` (HTTP 200) to verify bot identity before
diagnosing deeper issues.
```

O loop de melhoria contínua (atualizado)

O loop de melhoria contínua

3 caminhos convergem: GEPA, manual, auto



GEPA: evolução genética de prompts

Genetic-Pareto Prompt Evolution — paper ICLR 2026

1. Lê a skill atual
2. Gera dataset de execuções reais (traces)
3. Roda o otimizador GEPA (custo ~\$2–10, **sem GPU**)
4. Avalia candidatos em Pareto front
5. Aplica constraints (segurança, estilo)
6. Abre PR com a melhor variante

*Skills **melhoram sozinhas** em background. O arreio fica mais justo a cada passada.*

Comparativo: por que não só ChatGPT?

Critério	ChatGPT	Codex CLI	Hermes v2
Harness engineering completo	✗	parcial	✓ (8/8 componentes)
Memória persistente multi-tier	✗	✗	✓ 3 tiers
Skills customizadas versionadas	✗	via filesystem	✓ agentskills.io
Auto-geração de skills	✗	✗	✓ ≥5 tool calls
6+ canais de messaging	✗	✗	✓
Modelo-agnóstico	✗	✗	✓
Provedor próprio (UNESP)	✗	✗	✓ llm.tools.unesp.br
Privacidade (local-first)	✗	parcial	✓ modelo local possível
Open source MIT	✗	✗	✓
Evolução offline (GEPA)	✗	✗	✓

Integração com a UNESP


- **Claude-Unesp**: `llm.tools.unesp.br` (dados não saem)
- **Notion**: gestão de tarefas institucionais via `notion` skill
- **Google Workspace**: `gws` CLI (Gmail, Calendar, Drive)
- **GitHub**: PRs, issues, code review via `github` skill
- **Teams**: pipeline de reuniões → action items → Notion
- **AgentMail**: e-mails automáticos com triagem inteligente
- **REDNESP / C3SP**: HPC assistido por IA (em rollout)

Omarchy: o SO controlado por agentes

Omarchy (Arch Linux baseado) é o **laboratório vivo** do Hermes — cada componente do sistema é uma skill, e cada skill vira um comando que a IA pode invocar.



Cadeia 100% software livre



Onde estamos vs. fronteira

Capacidade	Estado hoje	Fronteira 2026
Skills estáticas	✓ 118 bundled	meta-skills auto-crossing (MCE)
Memória multi-tier	✓ 3 tiers	playbooks evolutivos (ACE)
Gateway multiplex	✓ produção	agentes em rede via A2A
Voz conversacional	✓ real-time	prosódia emocional, dialetos
Auto-aprimoramento	✓ manual+GEPA	harness que evolui sozinho (AHE)
Multi-tenant	parcial	per-tenant context studios

| *Hermes está **no mainline** da fronteira open-source — não atrás dela.*

O que vem por aí (próximos 6-12 meses)

- **Ralph Loops** no Hermes: agentes rodam até PR mergeado, sem humano no loop
- **A2A inter-profile**: bots conversando entre si (linus ↔ vargani)
- **AHE** (Agentic Harness Engineering): observabilidade que evolui o harness automaticamente
- **RAG semântico** sobre wiki UNESP com embeddings locais
- **Agentes verticais**: bioinfo (ideker), pedagogy (klimt), procurement (vargani)
- **HaaS** (Harness-as-a-Service): hospedar o harness de terceiros

Arreios bem ajustados

não prendem — liberam

Eles evoluem enquanto você trabalha

Em uma frase

O Hermes não é mais um assistente de IA.

*É um **harness completo** que **se autoaperfeiçoa** —
e que entende quem você é, o que você faz, e como você fala.*

Liberte-se

*"Emancipate yourselves from mental slavery.
None but ourselves can free our minds."*

— **Bob Marley, *Redemption Song* (1980)**

A engenharia de IA tem a mesma forma: **ninguém vai libertar seu workflow a não ser você mesmo**. Cada camada que você controla (SO, LLM, arreio, apps, bots) é uma camada de soberania que nenhum fornecedor pode tirar de você.

Perguntas?

Ney Lemke

CIO · UNESP · CTInf

ney.lemke@unesp.br

Referências (selecionadas)

- OpenAI. "Harness engineering: leveraging Codex in an agent-first world." fev/2026. openai.com/index/harness-engineering/
- Anthropic. "Effective harnesses for long-running agents." jan/2026.
- Böckeler, B. "Harness engineering." martinfowler.com. fev/2026.
- Osmani, A. "Agent Harness Engineering." O'Reilly Radar. mai/2026.
- Weng, L. "Harness Engineering for Self-Improvement." Lil'Log. jul/2026. lilianweng.github.io/posts/2026-07-04-harness/
- Masood et al. "'Harness Engineering' Emerges as the Fourth Paradigm of AI Engineering." TechTimes. mai/2026.
- Manchikanti, K. "How 60 production agents actually self-improve." LinkedIn. 2026.
- Ning et al. "Harness Engineering for Agentic AI Coding Tools." arXiv:2602.14690. 2026.
- LangChain. "The Anatomy of an Agent Harness." mar/2026.
- Addy Osmani / OpenAI. "Harness engineering: leveraging Codex in an agent-first world." 2026.
- Nous Research. Hermes Agent v0.10 (abr/2026) → v0.13 Tenacity (mai/2026) → v0.21 (atual).
- Zhang et al. "Agentic Context Engineering (ACE)." 2025.
- Ye et al. "Meta Context Engineering (MCE)." 2026.
- Lin et al. "Agentic Harness Engineering: Observability-Driven Automatic Evolution of Coding-Agent Harnesses." arXiv:2604.25850. 2026.
- Hermes Agent docs. hermes-agent.nousresearch.com/docs